

UNIVERSITÀ DEGLI STUDI DI SALERNO

Laurea Magistrale in Scienze Statistiche per la Finanza

Analisi sul numero di famiglie con figli minorenni negli USA

Progetto del corso in
Analisi delle Serie Storiche

A.A. 2024/2025

Cristian Avagnano	n. mat. 0222401035
Giuseppe Saviano	n. mat. 0222401033
Simone Squizzato	n. mat. 0222401031

Indice

1 Introduzione alla Serie Storica 4

2 Analisi delle caratteristiche della serie 5

3 Identificazione del modello 11

4 Analisi delle performance previsive 13

Elenco delle figure

Figura 1.1: Time-Series Plot della serie 4

Figura 2.1: ACF della serie originale 5
Figura 2.2: PACF della serie originale 5
Figura 2.3: Mean-SD Deviation Plot della serie originale 6
Figura 2.4: Mean-SD Plot della serie trasformata 6
Figura 2.5: Time-Series Plot della serie trasformata e differenziata di ordine 1 . . 7
Figura 2.6: ACF Plot della serie trasformata e differenziata di ordine 1 7
Figura 2.7: PACF Plot della serie trasformata e differenziata di ordine 1 8
Figura 2.8: ADF Test della serie trasformata e differenziata di ordine 1 8
Figura 2.9: Time-Series Plot della serie trasformata e differenziata di ordine 2 . . 9
Figura 2.10: ACF della serie trasformata e differenziata di ordine 2 9
Figura 2.11: PACF della serie trasformata e differenziata di ordine 2 9
Figura 2.12: ADF Test della serie trasformata e differenziata di ordine 2 10

Figura 3.1: Stima dei parametri modello ARIMA(0,2,1) 11
Figura 3.2: Test sui coefficienti del modello ARIMA(0,2,1) 11
Figura 3.3: Analisi dei residui del modello ARIMA(0,2,1) 12
Figura 3.4: Jarque-Bera Test sui residui del modello ARIMA(0,2,1) 12

Figura 4.1: Time-Series Plot delle previsioni con modello ARIMA(0,2,1) 13
Figura 4.2: Confronto performance previsive 14

1 Introduzione alla Serie Storica

Il dataset analizzato contiene una serie di informazioni relative al numero di famiglie sposate con figli minorenni negli Stati Uniti annualmente a partire dal 1950 fino al 2019. L'analisi condotta inizia dal Time-Series plot della serie:

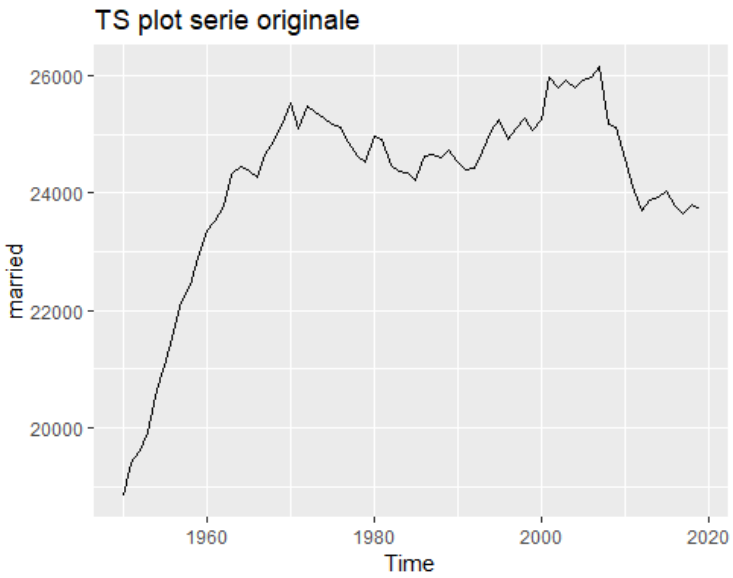


Figura 1.1: Time-Series Plot della serie

Dal plot della serie si evince un possibile trend crescente, in particolare per le prime osservazioni della serie, risultando dunque essere non stazionaria in media. È ragionevole affermare che la serie sia non stazionaria anche in varianza, dato che anche la variabilità della serie sembra cambiare al passare del tempo. Le considerazioni fatte finora hanno come ovvia conseguenza che la serie non sia la realizzazione finita di un processo stocastico stazionario. Procediamo ora all'analisi specifica delle caratteristiche della serie.

2 Analisi delle caratteristiche della serie

La non stazionarietà in media è facilmente dimostrabile anche dal grafico delle autocorrelazioni globali e parziali della serie:

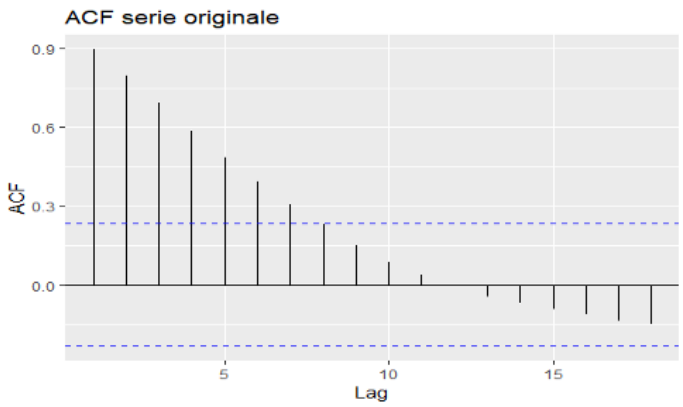


Figura 2.1: ACF della serie originale

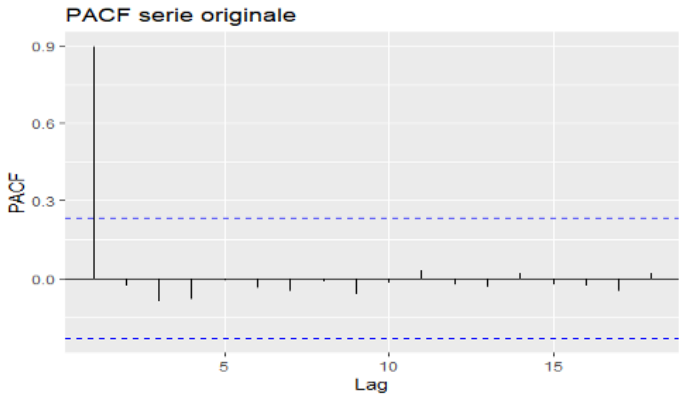


Figura 2.2: PACF della serie originale

Dalle autocorrelazioni globali è evidente la non stazionarietà in media della serie, dato che esse decrescono lentamente a zero, confermando così la possibile presenza di un trend nella serie. Per verificare la non stazionarietà in varianza della serie, invece, è utile la visualizzazione del Mean-Standard Deviation plot:

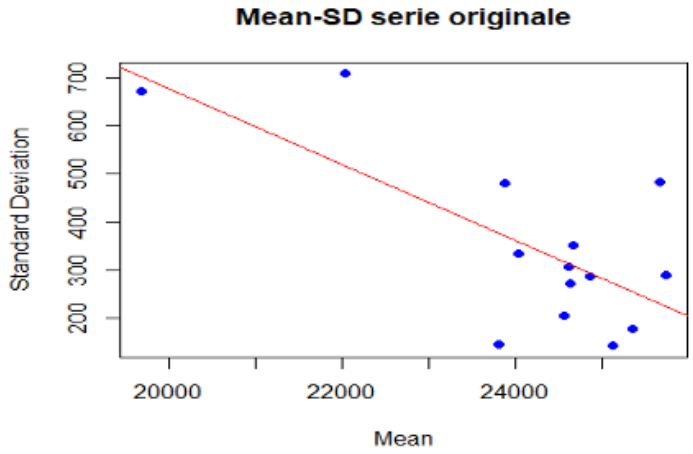


Figura 2.3: Mean-SD Deviation Plot della serie originale

Il mean-standard deviation plot della serie conferma come essa non sia stazionaria in varianza dato che i punti non si distribuiscono attorno a una retta parallela all'asse delle ascisse. In tal senso, è possibile rendere la serie stazionaria in varianza attraverso le trasformazioni di Box-Cox. Le trasformazioni di Box-Cox sono delle trasformazioni parametriche finalizzate a stabilizzare la varianza per ottenere delle serie lineari. Esse sono così definite:

$$Y_t = \begin{cases} (X_t^\lambda - 1)/\lambda & \text{se } \lambda \neq 0 \\ log(X_t) & \text{se } \lambda = 0 \end{cases}$$

La scelta del λ ottimale è fondamentale per ottenere la trasformata della serie che meglio stabilizza la varianza. La trasformata più comune e facilmente interpretabile è quella logaritmica, ottenuta ponendo $\lambda = 0$:

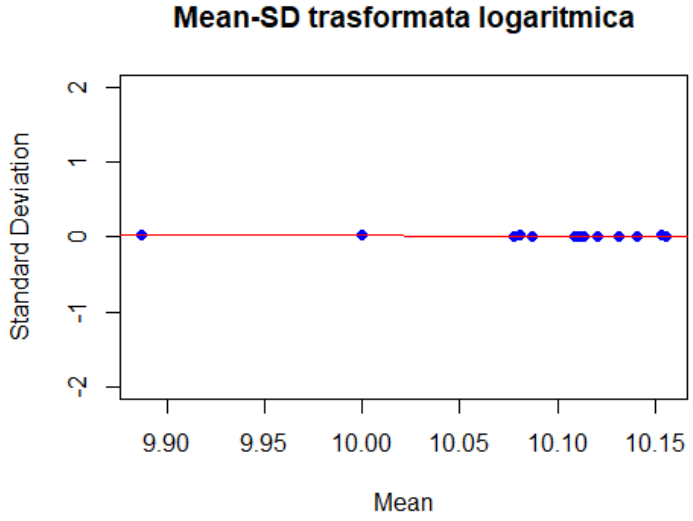


Figura 2.4: Mean-SD Plot della serie trasformata

Ripetendo il Mean-SD plot per la serie trasformata logaritmica si può notare come questa sia stazionaria in varianza, con i suoi punti che si distribuiscono attorno a una retta parallela all'asse delle x.
Risolto il problema della non stazionarietà in varianza, rimane comunque quello della non stazionarietà in media, dato che la trasformata logaritmica non ha ovviamente rimosso il trend. Una soluzione è applicare la differenziazione alla trasformata logaritmica, la quale viene applicata fin quando il trend non viene rimosso.
Si parte dalle differenze prime, le quali sono ottenute come la differenza tra la serie storica, in questo caso la trasformata logaritmica, al tempo t e la serie al tempo t-1:

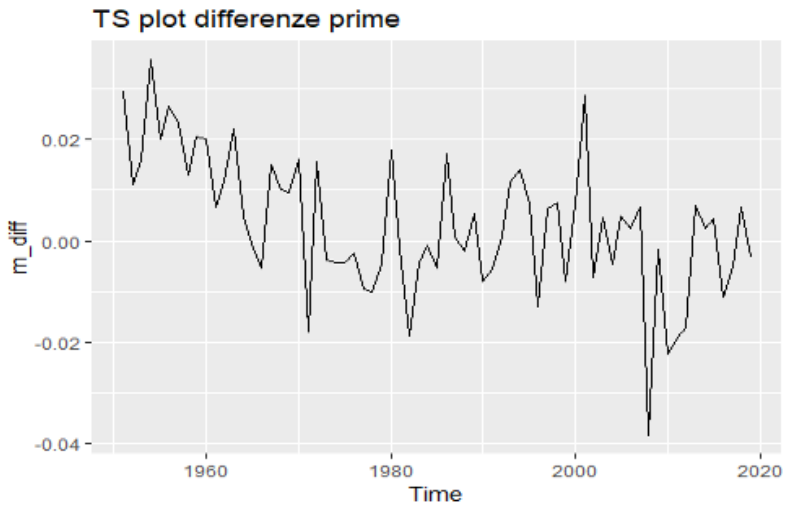


Figura 2.5: Time-Series Plot della serie trasformata e differenziata di ordine 1

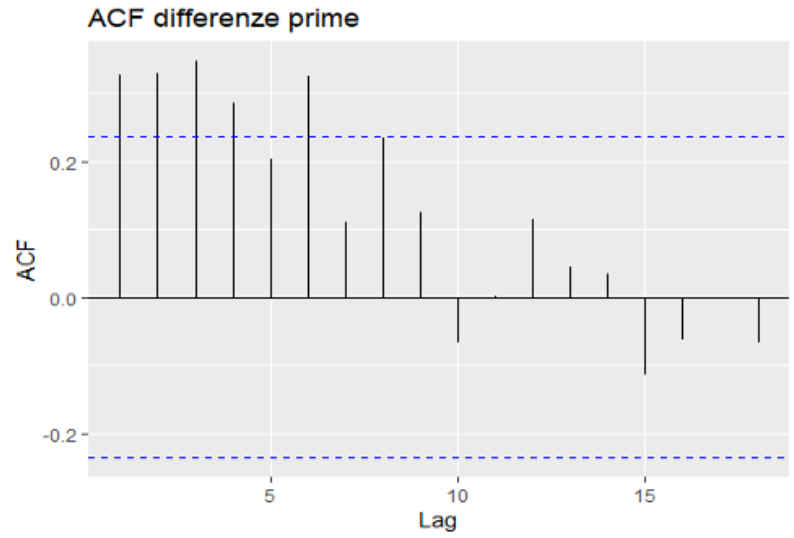


Figura 2.6: ACF Plot della serie trasformata e differenziata di ordine 1

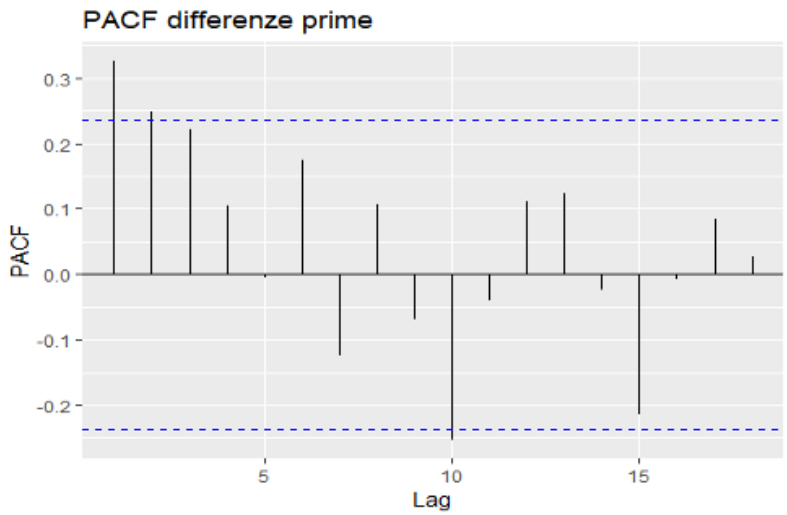


Figura 2.7: PACF Plot della serie trasformata e differenziata di ordine 1

Dal grafico delle ACF, che sembra decadino lentamente a zero, si evince la possibilità che il trend sia ancora presente. A conferma di ciò, è possibile costruire l'Augmented Dickey-Fuller test:

```
        Augmented Dickey-Fuller Test

data:  m_diff
Dickey-Fuller = -2.8366, Lag order = 4, p-value =
0.2352
alternative hypothesis: stationary
```

Figura 2.8: ADF Test della serie trasformata e differenziata di ordine 1

I risultati del test confermano come il trend sia ancora presente nonostante la serie delle differenze prime applicate alla trasformata logaritmica. Infatti, il valore del p-value, maggiore della soglia limite fissata a 0.05, indica come non si rifiuta l'ipotesi H_0 di non stazionarietà in media della serie.
Si applicano ora le differenze seconde alla trasformata, così da verificare se il trend presente è finalmente rimosso:

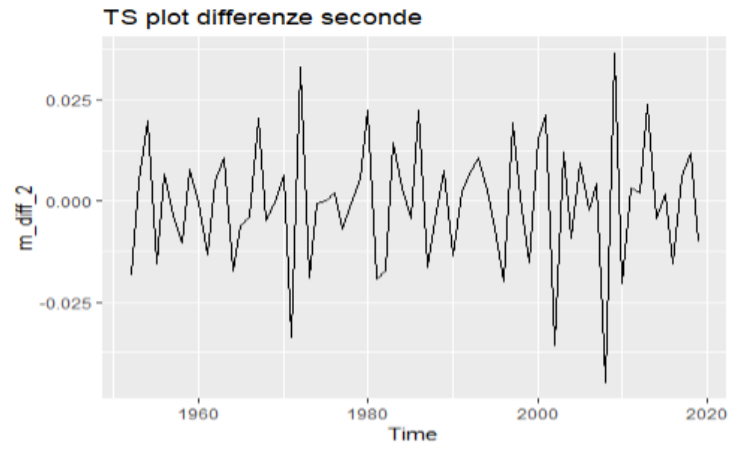


Figura 2.9: Time-Series Plot della serie trasformata e differenziata di ordine 2

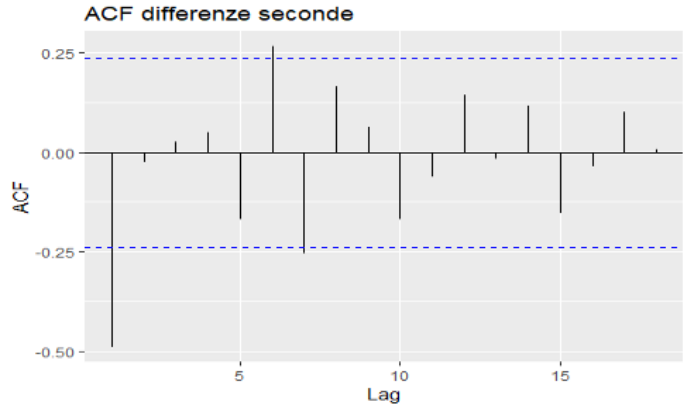


Figura 2.10: ACF della serie trasformata e differenziata di ordine 2

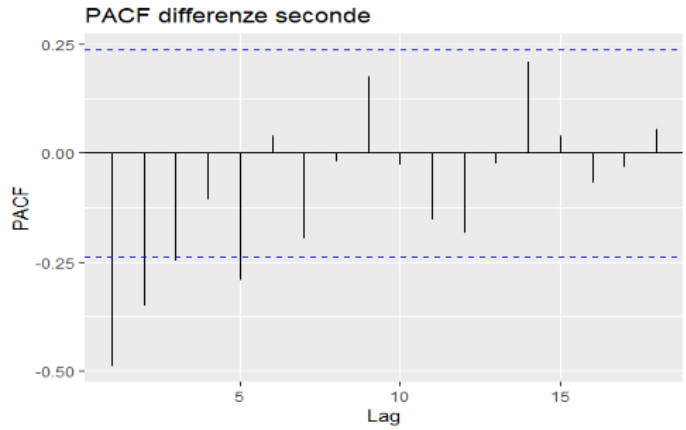


Figura 2.11: PACF della serie trasformata e differenziata di ordine 2

Le differenze seconde sembrano finalmente aver rimosso il trend dalla trasformata logaritmica, come è possibile notare sia dal TS plot che dal grafico delle autocorrelazioni. A conferma di ciò, utilizziamo l'ADF test:

```
        Augmented Dickey-Fuller Test

data:  m_diff_2
Dickey-Fuller = -6.4742, Lag order = 4, p-value = 0.01
alternative hypothesis: stationary
```

Figura 2.12: ADF Test della serie trasformata e differenziata di ordine 2

Il test conferma che la serie è stazionaria in media, dato che il valore del p-value è minore della soglia 0.05, per cui si rifiuta l'ipotesi H_0 di non stazionarietà in media della serie.
Detto ciò, partendo dalle valutazioni delle ACF e PACF, identifichiamo un possibile modello per la nostra serie storica.

3 Identificazione del modello

Dall'analisi delle ACF e delle PACF della serie differenziata due volte sembra che la sola autocorrelazione globale al lag 1 sia significativa, mentre le PACF sembrano decrescere a zero. Sulla base di queste osservazioni è possibile stimare diversi modelli possibili per la serie. Si parte considerando il modello più semplice valutabile in questo caso, ossia un modello MA(1), o meglio, un modello ARIMA(0,2,1). Si analizza di seguito la significatività dei coefficienti del modello così stimato:

```
ARIMA(0,2,1)

Coefficients:
          ma1
      -0.7830
s.e.   0.0718

sigma^2 = 0.0001442:  log likelihood = 204.94
AIC=-405.87   AICc=-405.69   BIC=-401.44
```

Figura 3.1: Stima dei parametri modello ARIMA(0,2,1)

```
z test of coefficients:

     Estimate Std. Error z value  Pr(>|z|)
ma1 -0.782959   0.071794 -10.906 < 2.2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Figura 3.2: Test sui coefficienti del modello ARIMA(0,2,1)

Dal test sulla significatività dei coefficienti del modello si evince come il coefficiente MA(1) sia significativo. Inoltre, la stima del coefficiente è minore di 1 in valore assoluto, per cui rispetta le condizioni di invertibilità di un processo MA(1).
Dati i risultati ottimi ottenuti finora sul modello ARIMA(0,2,1), si passa ora all'analisi dei residui del modello, così da accertare che esso sia effettivamente adeguato per la serie considerata. In particolare, si analizza l'andamento dei residui attraverso il TS plot e il grafico delle loro autocorrelazioni globali, oltre che a valutarne la normalità sia a livello grafico che attraverso la costruzione del test di Jarque-Bera:

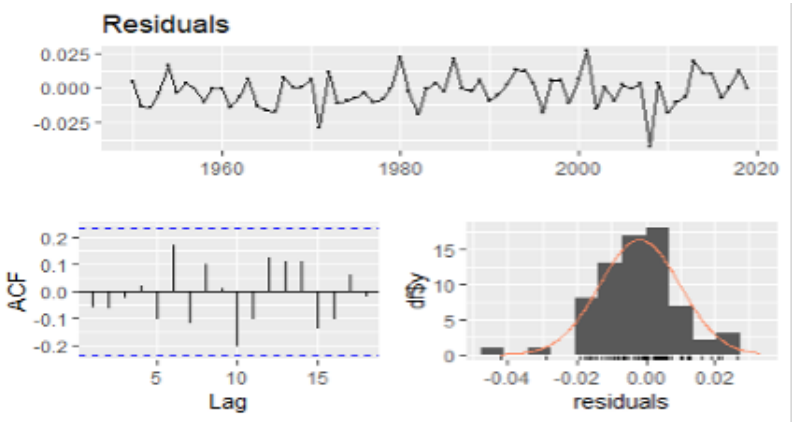


Figura 3.3: Analisi dei residui del modello ARIMA(0,2,1)

```
        Jarque Bera Test

data:  m3$residuals
X-squared = 5.7848, df = 2, p-value = 0.05544
```

Figura 3.4: Jarque-Bera Test sui residui del modello ARIMA(0,2,1)

L'analisi dei residui del modello ARIMA(0,2,1) sembra confermare come il modello identificato sia ottimale per la serie. Infatti, dal TS plot dei residui si evince come essi si distribuiscano intorno a zero, lasciando intendere come nel modello stimato non ci siano altre strutture dimenticate che potessero aiutare a spiegare meglio la serie. Anche il grafico delle ACF dei residui va in questa direzione, dato che tutte le autocorrelazioni globali rientrano nelle bande di confidenza, risultando, dunque, essere tutte non statisticamente significative. Il test sulla normalità dei residui, invece, fornisce dei risultati al limite, dato che il valore del p-value è prossimo alla soglia di rifiuto dell'ipotesi H_0, per cui non è possibile effettuare considerazioni precise sulla normalità dei residui.

4 Analisi delle performance previsive

L'analisi condotta sulla serie originale e i relativi risultati osservati rimangono pressoché invariati considerando una suddivisione della serie stessa in training e test set. In particolare, si considera circa l'85% delle osservazioni per la costruzione del training set (dal 1950 al 2008) e il restante 15% circa per il test set (dal 2009 al 2019). Lo split dei dati consente di valutare le performance previsive del modello selezionato sulla serie originale.
Si analizzano di seguito le previsioni fornite dal modello identificato, ossia il modello ARIMA(0,2,1):

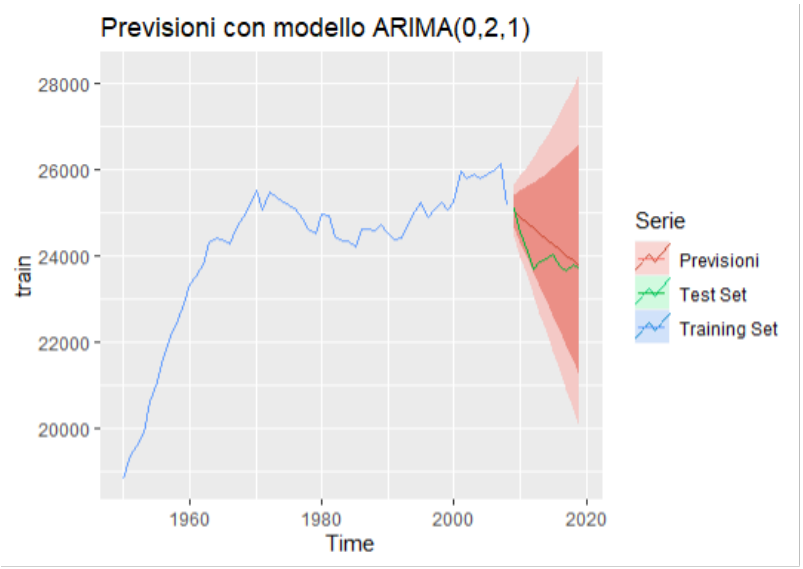


Figura 4.1: Time-Series Plot delle previsioni con modello ARIMA(0,2,1)

Dato che il processo sul quale vengono effettuate le previsioni presenta una sola componente MA, le previsioni effettuate ad un lag maggiore di 1 sarebbero nulle data l'assenza di errori futuri, i quali a partire dal lag 2 sono predetti nulli. Per questo motivo, è stato adottato un procedimento di previsione step-by-step, il quale effettua dapprima una previsione al tempo t+1 utilizzando i dati osservati fino al tempo t, poi, una volta ottenuta la previsione per il tempo t+1, quest'ultima viene assunta come un valore osservato per effettuare la previsione al tempo t+2. Il procedimento è ripetuto fino all'ultima previsione effettuata. Dalle stime ottenute si può notare il comportamento della varianza, che tende a crescere di pari passo all'aumentare del lag per il quale viene effettuata la previsione.
Per accertare la bontà delle previsioni effettuate col modello ARIMA(0,2,1) si confrontano i risultati ottenuti da tali previsioni con quelli ottenuti con altri metodi di previsione più semplici, tra cui il mean method, il naive method e il drift method:

	Method	RMSE	MAE	MAPE
1	ARIMA(0,2,1)	473.3851	388.1965	1.621886
2	Naive	1195.5721	1113.2000	4.660321
3	Mean	466.0888	418.9307	1.738125
4	Drift	1939.2292	1799.5204	7.540159

Figura 4.2: Confronto performance previsive

I risultati mostrano come le previsioni ottenute col modello ARIMA siano di gran lunga preferibili rispetto a quelle ottenute col metodo naive e col metodo drift, dato che il modello ARIMA risulta avere valori migliori per ogni misura di accuratezza previsiva rispetto ai due metodi. Invece, il mean method risulta avere dei risultati in linea con quelli forniti dal modello ARIMA; tuttavia sono comunque preferibili le previsioni effettuate dal modello ARIMA(0,2,1) dato che quest'ultimo fornisce informazioni anche sulle componenti della serie.